

Вопрос 1. Что означает понятие «три V» в контексте больших данных? -> b) Объём, разнообразие, скорость

Вопрос 2. Какую библиотеку Python в лекции называют самой популярной для машинного обучения? -> c) Scikit-learn

Вопрос 3. Что из перечисленного является ключевым отличием потоковых данных? -> c) Они поступают в систему по событиям, а не загружаются большими массивами

Вопрос 4. Какой язык используется для управления структурированными данными в реляционных базах данных? -> d) SQL

Вопрос 5. Что такое распределённая файловая система? -> c) Система, работающая на нескольких серверах одновременно и скрывающая сложность от пользователя

Вопрос 6. Что означает «No» в термине NoSQL по мнению лекции? -> b) Not only (не только SQL)

Вопрос 7. Какие из перечисленных типов данных относятся к категориям данных по версии лекции? -> a, b, c) Структурированные; Полуструктурированные; Неструктурированные

Вопрос 8. Какие из перечисленных инструментов упоминаются в лекции как относящиеся к экосистеме больших данных? -> a, b, d, e) Apache Sqoop; Apache Flume; Spark; TensorFlow

Вопрос 9. Какие характеристики соответствуют распределённому программированию? -> b, c) Вы перемещаете программу к данным; Требуется перезапуск сбойных заданий

Вопрос 10. Какие шаги включает процесс data science согласно лекции? -> a, b, d, e) Назначение цели исследования; Сбор и подготовка данных; Моделирование; Отображение и автоматизация

Вопрос 11. Установите соответствие между типом базы данных и описанием. -> 1) Столбцовые базы данных — хранение по столбцам; 2) Хранилища документов — А) не используют таблицы, хранят полную информацию об объекте; 3) Графовые базы данных — В) используют узлы, рёбра и свойства для моделирования связей; 4) Хранилища «ключ-значение» — Г) каждому значению сопоставляется ключ

Вопрос 12. Установите соответствие между категорией инструментов и назначением. -> 1) Планирование — автоматизация запуска заданий; 2) Развертывание системы — развертывание/предоставление доступа к приложению как к сервису; 3) Программирование — разработка служб; 4) Сравнительный анализ — Г) оптимизация за счёт стандартизированных профилей

Вопрос 13. Что означает принцип «локализация данных» (Data Locality)? -> 2) Перемещение вычислительных задач на узлы, где физически хранятся данные

Вопрос 14. Какое утверждение лучше всего описывает горизонтальное масштабирование? -> 3) Добавление новых серверов в кластер для распределения нагрузки

Вопрос 15. Какая основная цель репликации блоков данных в HDFS? -> 2) Обеспечение отказоустойчивости при выходе из строя узлов кластера

Вопрос 16. Какой компонент экосистемы Hadoop является менеджером ресурсов? -> 3) YARN

Вопрос 17. В модели MapReduce какая задача выполняется на фазе Shuffle? -> 2) Сбор результатов со всех Map-задач, их сортировка и распределение по Reduce-задачам

Вопрос 18. Почему классический Hadoop MapReduce считается медленным для итеративных алгоритмов? -> 2) Результаты каждой фазы (Map и Reduce) записываются на диск

Вопрос 19. Что такое RDD в Apache Spark? -> 3) Основная абстракция Spark, представляющая устойчивый распределённый набор данных

Вопрос 20. За счёт какого механизма Apache Spark восстанавливает потерянные данные при падении узла? -> 3) Использование lineage — графа преобразований

Вопрос 21. Какую ключевую функцию выполняет Apache Kafka в архитектуре обработки потоковых данных? -> 2) Высокопроизводительный буфер (брокер сообщений)

Вопрос 22. Как называется нумерация сообщений в Kafka и что она гарантирует внутри одной партиции? -> 2) Offset (смещение) — гарантирует порядок сообщений

Вопрос 23. В чем основное различие между Lambda и Карра архитектурами обработки данных? -> 3) Lambda требует поддержки двух кодовых баз (batch и stream), а Карра использует один потоковый движок

Вопрос 24. Для банковской системы, обрабатывающей платежи, какой уровень гарантии доставки сообщений должен быть настроен? -> 3) Exactly-once

Вопрос 25. Какой компонент Hadoop отвечает за хранение метаданных файловой системы? -> C) NameNode

Вопрос 26. Какое значение коэффициента репликации используется в HDFS по умолчанию? -> C) 3

Вопрос 27. Какой компонент YARN договаривается о ресурсах для конкретного приложения? -> C) ApplicationMaster

Вопрос 28. В какой фазе MapReduce происходит сортировка и передача данных от мапперов к редьюсерам? -> C) Shuffle

Вопрос 29. Какое утверждение о Hive верно? -> B) Hive транслирует SQL-запросы в задачи MapReduce

Вопрос 30. Для каких целей лучше всего подходит Apache HBase? -> C) Для быстрого доступа к записи по ключу (row key)

Вопрос 31. Какое ключевое свойство Spark позволяет ему обгонять MapReduce в задачах машинного обучения? -> B) Хранение промежуточных данных в памяти

Вопрос 32. Что произойдет с данными в HDFS, если один из DataNode выйдет из строя? -> C) Данные будут считаны с реплик на других узлах, и NameNode инициирует создание новых копий

Вопрос 33. Какой язык используется для написания скриптов в Apache Pig? -> B) Pig Latin

Вопрос 34. Какой компонент Hadoop управляет ресурсами и позволяет запускать разные фреймворки на одном кластере? -> B) YARN

Вопрос 35. Какой API Spark является самым первым и низкоуровневым? -> A) RDD

Вопрос 36. Что из перечисленного является действием (Action) в Spark? -> D) .count()

Вопрос 37. Какая концепция Spark позволяет строить план вычислений без немедленного выполнения? -> B) Ленивые вычисления (Lazy Evaluation)

Вопрос 38. Какой оптимизатор лежит в основе DataFrame и Dataset API? -> B) Catalyst

Вопрос 39. Какой механизм Spark восстанавливает потерянные данные без репликации? -> B) Lineage (родословная)

Вопрос 40. Какой компонент Spark отвечает за управление памятью вне кучи JVM и генерацию эффективного байт-кода? -> B) Tungsten

Вопрос 41. Для какого языка доступна типизированная версия Spark API — Dataset? -> C) Scala

Вопрос 42. Что произойдет при выполнении `df.filter(...).select(...)`? -> B) Будет построен логический план, но реального вычисления не произойдет

Вопрос 43. Как зарегистрировать DataFrame `peopleDF` для SQL-запросов? -> B) `peopleDF.createOrReplaceTempView("people")`

Вопрос 44. Какая стратегия JOIN будет использована Spark, если одна таблица очень маленькая? -> B) BroadcastHashJoin

Вопрос 45. В чем преимущество хранения данных в Parquet при использовании Spark? -> B) Spark может читать только нужные колонки (projection pushdown), экономя I/O

Вопрос 46. Какой метод нельзя вызвать у RDD? -> D) `.groupBy().agg()`

Вопрос 47. Что такое Checkpointing в Spark? -> A) Сохранение RDD в надёжное хранилище с обрывом lineage

Вопрос 48. Какая структура данных в Spark обеспечивает типизированный доступ и Catalyst-оптимизатор? -> C) Dataset

Вопрос 49. Какая архитектура интеграции Spark и Deep Learning рекомендуется для больших моделей на 10+ GPU? -> c) Horovod

Вопрос 50. Какие проблемы анализа Big Data упоминаются в лекции? -> a, b, d, e) Проклятие размерности; $O(n^2)$ для попарных расстояний; Однопроходные алгоритмы; Pandas не работает при 500 ГБ данных

Вопрос 51. Какой компонент Kafka хранит данные и обслуживает запросы на чтение/запись? -> D) Broker

Вопрос 52. Что происходит с сообщением в Kafka после чтения Consumer? -> C) Сообщение остается в логе на время, заданное retention policy

Вопрос 53. Какая модель обработки лежит в основе Apache Flink? -> B) Native streaming (обработка событие за событием)

Вопрос 54. Какой API Spark используется для современной потоковой обработки? -> B) Structured Streaming (на DataFrame)

Вопрос 55. Что такое offset в Kafka? -> D) Уникальный номер сообщения внутри партии

Вопрос 56. Для чего нужна Consumer Group в Kafka? -> B) Для распределения партиций между потребителями

Вопрос 57. Какой фреймворк обеспечивает самую низкую задержку при потоковой обработке? -> B) Apache Flink

Вопрос 58. Что такое Watermark в потоковой обработке? -> C) Маркер, указывающий, что все события до определенного времени получены

Вопрос 59. Какая гарантия означает обработку ровно один раз? -> C) Exactly-once

Вопрос 60. Что произойдет, если в Consumer Group добавить больше потребителей, чем партиций? -> C) Лишние потребители будут простаивать

Вопрос 61. Какой инструмент является стандартом де-факто для транспорта событий? -> C) Apache Kafka

Вопрос 62. В каком сценарии Spark Streaming может быть предпочтительнее Flink? -> C) В инфраструктуре уже используется Spark для batch и ML

Вопрос 63. Что означает NoSQL в современном понимании? -> B) Not Only SQL

Вопрос 64. Какой тип NoSQL-баз данных представляет MongoDB? -> B) Документоориентированный

Вопрос 65. Какая база данных использует masterless-архитектуру? -> C) Cassandra

Вопрос 66. Для каких задач оптимально подходят графовые базы данных? -> D) Социальные сети и фрод-мониторинг

Вопрос 67. Какое главное преимущество колоночного хранения данных? -> C) Эффективные агрегации на больших объемах

Вопрос 68. Какой язык запросов используется в Neo4j? -> D) Cypher

Вопрос 69. Какая теорема описывает компромиссы между согласованностью, доступностью и устойчивостью к разделению? -> B) CAP-теорема

Вопрос 70. Для какого сценария лучше всего подходит Redis? -> C) Кэширование и хранение сессий

Вопрос 71. Какая база данных была разработана в Яндексе для веб-аналитики? -> D) ClickHouse

Вопрос 72. Какая из NoSQL-баз поддерживает полноценные ACID-транзакции? -> C) Neo4j

Вопрос 73. Что означает денормализация в NoSQL? -> B) Хранение избыточных данных для ускорения чтения

Вопрос 74. Какой тип NoSQL-баз лучше всего подходит для анализа временных рядов? -> C) Колоночный (ClickHouse)

Вопрос 75. Какая модель облачных услуг предоставляет готовый настроенный кластер? -> B) PaaS

Вопрос 76. Сколько копий данных хранит Yandex Object Storage для отказоустойчивости? -> C) 3 копии в разных зонах доступности

Вопрос 77. Какой протокол используется в Spark для доступа к Yandex Object Storage? -> C) s3a://

Вопрос 78. Какой принцип лежит в основе экономичной облачной архитектуры Big Data? -> B) Отделение вычислений от хранилища

Вопрос 79. Какой подкластер Data Proc отвечает за автомасштабирование под нагрузку? -> C) Compute

Вопрос 80. Какая компания использовала Yandex Data Proc для расчета метрик ликвидности? -> B) Московская биржа

Вопрос 81. Что позволяет экономить до 70% стоимости VM в Data Proc? -> B) Прерываемые виртуальные машины

Вопрос 82. Какой табличный формат используется для LakeHouse в кейсе с fashion-ритейлером? -> C) Apache Iceberg

Вопрос 83. Какой сервис выполняет SQL-запросы к данным в Object Storage без создания кластера? -> B) Yandex Query

Вопрос 84. Что нужно настроить для доступа кластера Data Proc в интернет? -> B) NAT-шлюз и таблицу маршрутизации

Вопрос 85. Какой API является стандартом для объектных хранилищ и поддерживается Yandex Object Storage? -> B) Amazon S3 API

Вопрос 86. Что такое IAM-токен в контексте Object Storage? -> B) Временный токен для безопасной аутентификации

Вопрос 87. Какая задача относится к классификации с учителем? -> b) Определение спама в электронных письмах

Вопрос 88. Какой алгоритм является стандартом для рекомендательных систем в Spark? -> c) ALS (Alternating Least Squares)

Вопрос 89. Какая проблема анализа Big Data описывается как $O(n^2)$ для попарных расстояний? -> c) Кластеризация

Вопрос 90. Какой подход интеграции Deep Learning и Spark назван устаревшим? -> c) Elephas / SparkFlow

Вопрос 91. Что такое проклятие размерности? -> b) Ухудшение качества моделей при слишком большом количестве признаков

Вопрос 92. Какой метод преобразования категориальных признаков используется в Spark MLlib? -> b) StringIndexer + OneHotEncoder

Вопрос 93. Какие варианты интеграции Spark и Deep Learning актуальны? -> a, c, d) Spark → TFRecord → TensorFlow; Petastorm; Horovod

Вопрос 94. Какие проблемы характерны для распределённого SGD? -> a, b, d) All-Reduce; Stale Gradients; синхронный vs асинхронный режим

Вопрос 95. Какие алгоритмы машинного обучения для Big Data упоминаются в лекции? -> a, b, c, d, e) Random Forest; Logistic Regression; K-Means; ALS; Decision Tree

Вопрос 96. Установите соответствие между термином и описанием. -> 1-A) Data Parallelism — модель копируется на каждый узел, данные режутся на партии; 2-Б) All-Reduce — усреднение градиентов; 3-В) Parameter Server — асинхронное обновление весов; 4-Г) Stale Gradients — устаревшие градиенты

Вопрос 97. Установите соответствие между вариантом интеграции Spark и DL и характеристикой. -> 1-В) Spark → TFRecord → TensorFlow — простота, надёжность, двойное хранение; 2-А) Petastorm — maintenance-статус, читает Parquet; 3-Г) Horovod — MPI, линейное масштабирование на 10+ GPU; 4-Б) Elephas — устарел

Вопрос 98. Какой метод НЕ является способом интеграции Spark и Deep Learning? -> d) Pandas UDF для замены всех операций Spark ML

Вопрос 99. Какой инструмент предназначен преимущественно для мониторинга метрик временных рядов? -> C) Grafana

Вопрос 100. Какой компонент ELK отвечает за индексацию и хранение логов? -> D) Elasticsearch

Вопрос 101. Что означает overplotting? -> B) На графике слишком много точек, и они сливаются в одно пятно

Вопрос 102. Какой инструмент позволяет создать веб-дашборд без JavaScript, используя Python? -> C) Dash (Plotly)

Вопрос 103. Для чего используется spark.eventLog.enabled=true? -> B) Для записи событий Spark-приложения в HDFS/S3 для просмотра в Spark UI

Вопрос 104. Какой инструмент лучше всего подходит для ад-хок анализа и BI-дашбордов с небольшим бюджетом? -> C) Apache Superset

Вопрос 105. Что такое распределённый трейсинг? -> B) Отслеживание пути запроса через микросервисы с измерением времени в каждом

Вопрос 106. Какой инструмент НЕ предназначен для визуализации Big Data? -> B) Microsoft Excel

Вопрос 107. В чём основное ограничение Streamlit для Big Data? -> C) Плохо масштабируется при большом количестве одновременных пользователей

Вопрос 108. Какую проблему решает семплирование логов? -> B) Уменьшение объёма хранимых логов при сохранении репрезентативности

Вопрос 109. Какой механизм Kafka гарантирует порядок сообщений внутри партии? -> C) Offset (смещение)

Вопрос 110. Что такое Kafka Consumer Checkpointing в Flink? -> B) Периодическое сохранение offsets в State Backend для восстановления

Вопрос 111. Какое утверждение о Spark Structured Streaming верно? -> C) Позволяет строить потоковые запросы через SQL

Вопрос 112. Что такое Event Time vs Processing Time? -> B) Время события vs время обработки системой

Вопрос 113. Какая база данных относится к типу «ключ-значение»? -> C) Redis

Вопрос 114. Что означает Eventual Consistency? -> C) Данные станут согласованными со временем, если нет новых обновлений

Вопрос 115. Какой тип данных НЕ является стандартным для Redis? -> C) Graphs

Вопрос 116. В чём преимущество Cassandra перед реляционными СУБД для Big Data? -> B) Линейная масштабируемость при добавлении узлов без даунтайма

Вопрос 117. Какой сервис Yandex Cloud является управляемой БД для временных рядов? -> A) Yandex Managed Service for ClickHouse

Вопрос 118. Что такое прерываемые VM? -> B) VM со скидкой до 70%, которые могут быть остановлены провайдером

Вопрос 119. Какой протокол используется Prometheus для мониторинга и сбора метрик? -> A) HTTP/HTTPS с форматом plain text

Вопрос 120. Что такое Sunburst Chart? -> A) Круговая диаграмма с несколькими уровнями иерархии

Вопрос 121. Какой инструмент является центральным компонентом ELK для сбора и парсинга логов? -> C) Logstash

Вопрос 122. Какая метрика НЕ является стандартной для мониторинга JVM-приложений? -> D) Disk Queue Length

Вопрос 123. Что такое шардинг? -> B) Горизонтальное разделение данных на независимые части на разных узлах

Вопрос 124. Какая стратегия шардирования равномерно распределяет данные, но плохо поддерживает range-запросы? -> B) Хеш-шардинг

Вопрос 125. Что такое горячий шард? -> B) Шард, который получает непропорционально большую часть запросов

Вопрос 126. Какая модель репликации имеет единую точку отказа — мастер-узел? -> C) Master-Slave

Вопрос 127. Согласно CAP, какое свойство обязательно при возможных разрывах связи? -> C) Partition Tolerance

Вопрос 128. Какая стратегия кэширования пишет сначала в кэш, потом асинхронно в хранилище? -> C) Write-Behind

Вопрос 129. Какой метод инвалидации кэша гарантирует свежесть, но требует сигналов об изменении? -> B) Активная инвалидация

Вопрос 130. В какой системе используется Consistent Hashing? -> B) Apache Cassandra

Вопрос 131. Какая проблема возникает при JOIN таблиц, зашардированных по разным ключам? -> B) Данные нужно перетаскивать между шардами, что очень медленно

Вопрос 132. Сколько реплик блока данных в HDFS по умолчанию? -> C) 3

Вопрос 133. Что НЕ является стратегией шардирования? -> C) Master-Slave шардинг

Вопрос 134. Какая стратегия кэширования минимизирует засорение кэша редко запрашиваемыми данными при записи? -> D) Write-Around

Вопрос 135. Какая система является примером AP-системы? -> C) Apache Cassandra

Вопрос 136. Что означает co-location в контексте шардирования? -> B) Шардирование связанных таблиц по одному ключу, чтобы они были на одном узле

Вопрос 137. Какой метод инвалидации кэша требует проверки версии данных при каждом чтении? -> C) Версионирование

Вопрос 138. Что относится к аутентификации? -> B) Проверка, что пользователь ввёл правильный пароль

Вопрос 139. Какой фактор аутентификации относится к категории «что вы имеете»? -> A) Google Authenticator (OTP)

Вопрос 140. Какой протокол аутентификации является стандартом для Hadoop? -> C) Kerberos

Вопрос 141. Что означает RBAC? -> A) Role-Based Access Control

Вопрос 142. Какой инструмент является стандартом для централизованного управления политиками авторизации в Hadoop? -> B) Apache Ranger

Вопрос 143. Какое состояние данных защищает шифрование на уровне диска? -> B) Data at Rest

Вопрос 144. Какой тип шифрования используется для больших данных из-за скорости? -> C) Симметричное (AES)

Вопрос 145. Что такое KMS? -> A) Key Management System — система управления ключами шифрования

Вопрос 146. Какое шифрование защищает данные при передаче по сети? -> C) TLS/SSL

Вопрос 147. Что НЕ является задачей авторизации? -> C) Проверка, ввёл ли пользователь правильный пароль

Вопрос 148. Что такое TGT в Kerberos? -> B) Билет после аутентификации, позволяющий запрашивать другие билеты

Вопрос 149. Какая модель авторизации учитывает атрибуты пользователя, ресурса и окружения? -> B) ABAC

Вопрос 150. Почему HDFS Transparent Encryption называется прозрачной? -> B) Приложение не знает о шифровании и работает как обычно

Вопрос 151. Какое шифрование используется в TLS после установления соединения? -> D) Гибридное — асимметричное для обмена ключами, симметричное для данных

Вопрос 152. Что является грубым нарушением безопасности в production? -> B) Хранение ключей шифрования в коде или Git

Вопрос 153. Какой стек является классическим для централизованного сбора и анализа логов? -> B) ELK + Filebeat

Вопрос 154. Какой компонент ELK отвечает за визуализацию и дашборды? -> C) Kibana

Вопрос 155. Какой тип рекомендательной системы страдает от cold start? -> D) Все перечисленные, но особенно collaborative filtering

Вопрос 156. Какой алгоритм Spark MLlib используется для матричной факторизации в рекомендациях? -> B) ALS (Alternating Least Squares)

Вопрос 157. Какую БД чаще используют для хранения top-N рекомендаций для быстрого API-доступа? -> B) Redis (in-memory)

Вопрос 158. Какой протокол чаще всего используется для передачи данных от IoT-датчиков? -> B) MQTT

Вопрос 159. Что такое предиктивная аналитика в IoT на заводе? -> B) Прогнозирование отказа оборудования до его наступления

Вопрос 160. Какое облачное решение AWS предназначено для кластеров Spark и Hadoop? -> C) AWS EMR (Elastic MapReduce)

Вопрос 161. Как Google Dataproc интегрируется с аналитической БД GCP? -> B) Через BigQuery

Вопрос 162. Что НЕ является трендом Big Data? -> C) Отказ от распределённых систем в пользу одного мощного сервера

Вопрос 163. Какую задачу решает анализ логов веб-сервера? -> B) Выявление медленных запросов и ошибок HTTP 500

Вопрос 164. Какая команда GCP Dataproc удаляет кластер? -> B) gcloud dataproc clusters delete

Вопрос 165. Что является примером Data Lakehouse формата таблиц? -> B) Apache Iceberg / Delta Lake

Вопрос 166. Что НЕ является персональными данными по GDPR? -> C) Агрегированная статистика по продажам за месяц без привязки к людям

Вопрос 167. Какой максимальный штраф за серьёзное нарушение GDPR? -> B) €20 млн или 4% глобального годового оборота

Вопрос 168. Какое право позволяет потребовать передачу данных в машиночитаемом формате? -> C) Право на переносимость данных

Вопрос 169. Что НЕ является законным основанием обработки данных по GDPR? -> C) Коммерческий интерес компании, не сбалансированный с правами пользователя

Вопрос 170. Какой российский закон регулирует обработку персональных данных? -> A) 152-ФЗ «О персональных данных»

Вопрос 171. Что требует 152-ФЗ от компаний, обрабатывающих ПДн граждан РФ? -> B) Локализовать базы данных ПДн на территории РФ

Вопрос 172. Что такое псевдонимизация? -> B) Замена идентификаторов с возможностью обратного восстановления

Вопрос 173. Что является примером профилирования и дискриминации в Big Data? -> B) Кредитный скоринг, который занижает ставки из-за исторических предубеждений в данных

Вопрос 174. Что означает Privacy by Design? -> B) Защита данных встраивается в архитектуру и процесс разработки с самого начала

Вопрос 175. Сколько времени у компании по GDPR на выполнение запроса доступа к данным? -> В) 1 месяц с возможностью продления на 2 месяца

Вопрос 176. Какое основание обработки данных наименее предпочтительно этически? -> С) Неявное согласие через предзаполненные галочки в cookie-баннере

Вопрос 177. Кто контролирует соблюдение 152-ФЗ в России? -> В) Роскомнадзор

Вопрос 178. Что является специальной категорией персональных данных? -> В) Состояние здоровья

Вопрос 179. Как технически реализовать право на удаление в Big Data системе? -> В) Реализовать физическое удаление или обезличивание всех записей по идентификатору пользователя

Вопрос 180. Что является лучшей практикой Privacy by Default? -> С) Собирать только минимально необходимые данные, хранить их не дольше нужного срока и использовать псевдонимизацию